

1º trabalho de mineração

Marcelo da Silva Landim

2025-11-04

1.0 Descrição do trabalho

1.1 problema proposto

O seguinte trabalho tem como objetivo preparar um dataset para uma futura análise de risco, focando em micro-segmentos de risco para pessoa jurídica (PJ) no estado de Alagoas (AL). O processo envolve a filtragem e preparação de dados para posterior análise de risco creditício.

1.2 Descrição do processo

1.2.1 instalação dos pacotes utilizados

- **DuckDB**: Utilizado para processamento eficiente de dados em memória
- **dplyr**: Empregado para manipulação e transformação de dados
- **tibble**: Usado para melhor visualização de dataframes.

1.2.2 Configuração do Ambiente

- Conexão com banco de dados DuckDB em memória
- Definição do caminho do arquivo CSV contendo os dados originais.

1.2.3 Filtro aplicado nos Dados

- Aplicação de filtros específicos:
 - UF = 'AL' (Estado de Alagoas)
 - cliente = 'PJ' (Pessoa Jurídica)
- Execução via consulta SQL para eficiência.

1.2.4 Análise utilizadas

- Verificação da estrutura dos dados filtrados
- Estatísticas descritivas das variáveis numéricas
- Confirmação dos filtros aplicados.

1.3 Resultados Esperados

- Dataset filtrado contendo apenas PJs de Alagoas
- Base preparada para análises de risco subsequentes
- Documentação do processo de preparação.

2.0 Código R Utilizado

```
# Projeto- Preparação de Datasets para Análise de Risco
# Opção escolhida: 1 - Micro-Segmentos de Risco (Pessoa jurídica)
# UF escolhida: Alagoas (AL)

# Carregar as bibliotecas necessárias
library(tinytex)
library(duckdb)
library(dplyr)
library(tibble)

# Configurar conexão com DuckDB (banco de dados em memória)
con <- dbConnect(duckdb::duckdb(), dbdir = ":memory:")

# o caminho para o arquivo CSV baixado
caminho_csv <- "C:/Users/Katia/OneDrive/Documentos/marcelo/mineração de dados/minera-o/plani

# Filtros aplicados: UF = 'AL' AND cliente = 'PJ'
consulta_sql <- "
SELECT
  *
FROM
  read_csv_auto(?)
WHERE
  UF = 'AL'
  AND cliente = 'PJ'
```

```

"

# Executar a consulta e carregar os resultados em um dataframe
df_filtrado <- dbGetQuery(con, consulta_sql, list(caminho_csv))

# Fechar a conexão com o banco de dados
dbDisconnect(con)

# Análise exploratória do dataframe resultante
# Visualização rápida da estrutura dos dados
cat("=== ESTRUTURA DO DATAFRAME (glimpse) ===\n")

```

```

=== ESTRUTURA DO DATAFRAME (glimpse) ===

```

```

glimpse(df_filtrado)

```

```

Rows: 12,520
Columns: 23
$ data_base      <date> 2025-08-31, 2025-08-31, 2025-08-31, 20~
$ uf             <chr> "AL", "AL", "AL", "AL", "AL", "AL", "AL~
$ tcb           <chr> "Bancário", "Bancário", "Bancário", "Ba~
$ sr            <chr> "S1", "S1", "S1", "S1", "S1", "S1", "S1~
$ cliente       <chr> "PJ", "PJ", "PJ", "PJ", "PJ", "PJ", "PJ~
$ ocupacao      <chr> "-", "-", "-", "-", "-", "-", "-", "-",~
$ cnae_secao    <chr> "PJ - Administração pública, defesa e s~
$ cnae_subclasse <chr> "-", "-", "-", "-", "-", "-", "PJ - Adm~
$ porte        <chr> "PJ - Indisponível ~
$ modalidade   <chr> "PJ - Capital de giro", "PJ - Financiam~
$ origem       <chr> "Sem destinação específica", "Com desti~
$ indexador     <chr> "Flutuantes", "Flutuantes", "Pós-fixado~
$ numero_de_operacoes <chr> "<= 15", "<= 15", "<= 15", "<= 15", "<=~
$ a_vencer_ate_90_dias <chr> "27299837,92", "2546283,51", "332153,67~
$ a_vencer_de_91_ate_360_dias <chr> "67380965,36", "7994412,51", "971099,09~
$ a_vencer_de_361_ate_1080_dias <chr> "174605193,19", "24637011,88", "2412955~
$ a_vencer_de_1081_ate_1800_dias <chr> "172585915,84", "24637011,84", "2176193~
$ a_vencer_de_1801_ate_5400_dias <chr> "353847507,83", "46669004,91", "712940,~
$ a_vencer_acima_de_5400_dias <chr> "0,00", "0,00", "0,00", "0,00", "0,00",~
$ vencido_acima_de_15_dias <chr> "0,00", "0,00", "0,00", "0,00", "0,00",~
$ carteira_ativa <chr> "795719420,14", "106483724,65", "660534~
$ carteira_inadimplida_arrastada <chr> "0,00", "0,00", "0,00", "0,00", "0,00",~
$ ativo_problematICO <chr> "0,00", "0,00", "0,00", "0,00", "0,00",~

```

```
# Estatísticas descritivas das variáveis numéricas
cat("\n=== ESTATÍSTICAS DESCRITIVAS (summary) ===\n")
```

```
=== ESTATÍSTICAS DESCRITIVAS (summary) ===
```

```
summary(df_filtrado)
```

data_base	uf	tcb	sr
Min. :2025-08-31	Length:12520	Length:12520	Length:12520
1st Qu.:2025-08-31	Class :character	Class :character	Class :character
Median :2025-08-31	Mode :character	Mode :character	Mode :character
Mean :2025-08-31			
3rd Qu.:2025-08-31			
Max. :2025-08-31			

cliente	ocupacao	cnae_secao	cnae_subclasse
Length:12520	Length:12520	Length:12520	Length:12520
Class :character	Class :character	Class :character	Class :character
Mode :character	Mode :character	Mode :character	Mode :character

porte	modalidade	origem	indexador
Length:12520	Length:12520	Length:12520	Length:12520
Class :character	Class :character	Class :character	Class :character
Mode :character	Mode :character	Mode :character	Mode :character

numero_de_operacoes	a_vencer_ate_90_dias	a_vencer_de_91_ate_360_dias
Length:12520	Length:12520	Length:12520
Class :character	Class :character	Class :character
Mode :character	Mode :character	Mode :character

a_vencer_de_361_ate_1080_dias	a_vencer_de_1081_ate_1800_dias
Length:12520	Length:12520
Class :character	Class :character
Mode :character	Mode :character

```
a_vencer_de_1801_ate_5400_dias a_vencer_acima_de_5400_dias
Length:12520                      Length:12520
Class :character                  Class :character
Mode :character                   Mode :character
```

```
vencido_acima_de_15_dias carteira_ativa      carteira_inadimplida_arrastada
Length:12520                      Length:12520      Length:12520
Class :character                  Class :character Class :character
Mode :character                   Mode :character Mode :character
```

```
ativo_problematico
Length:12520
Class :character
Mode :character
```

```
# Verificação adicional dos filtros aplicados
cat("\n=== VERIFICAÇÃO DOS FILTROS ===\n")
```

```
=== VERIFICAÇÃO DOS FILTROS ===
```

```
cat("Valores únicos na coluna UF:", unique(df_filtrado$UF), "\n")
```

```
Valores únicos na coluna UF:
```

```
cat("Valores únicos na coluna cliente:", unique(df_filtrado$cliente), "\n")
```

```
Valores únicos na coluna cliente: PJ
```

```
cat("Dimensões do dataframe (linhas x colunas):", dim(df_filtrado), "\n")
```

Dimensões do dataframe (linhas x colunas): 12520 23